Sowii AI IP Agent框架

> 本文档主要讨论如何控制成本的情况下打造可落地的IP agent
>
> UGC工具的部分相对独立，不包括在此规划中

一、现状与目标

现状

1.0 版本中，秃秃的生活内容由内容组手工制作，按时间/天气等标签统一分发。核心问题有两个：

- **没有个性化**：所有用户看到的秃秃在做一样的事。秃秃不会因为你喜欢猫就多遇到猫，不会因为你心情不好就安静一些。
- **产能瓶颈**：5 人内容团队月产约 50 条，内容重复率高，用户几周就感觉"看过了"。影响「活的」感受

目标

让每个用户感受到"IP在过跟我有关的生活"，同时保证IP行为决策多样、内容品质过关（经过人工审核），成本不随用户规模线性增长。

要做什么

建立一个中心化的IP Agent 引擎，新的IP内容生产与分发系统模式，生产大量内容（万级别以上），解决：

1. **IP有主动性，有自己的生活，且IP的行为有丰富的变化**：单个用户的输入过于稀疏感受不到主动性

   ->Agent 从用户群体的真实行为中提取行为决策的意图输入。

   ->Agent主动推进收集signal的会话。

2. **让每个用户看到不同的IP**（分发侧）：每个用户一个agent后台始终“活着”，实时生成内容，成本上不落地

   ->内容一次生产多次分发，用每个用户的记忆summar，从池中匹配最合适的行为，再包装成个性化的文案呈现

> 💡 **底层逻辑：IP只有一个，但它和每个用户有不同的关系和记忆。**
>
> IP Agent规划行为，收集用户需求信号----->IP Agent筛选signal，自主决策行为，生产大量可被分发的IP内容----->根据不同个性化记忆，分发给不同用户不同内容并加以个性化包装

方案	内容量	个性化	内容品质	成本
传统 PGC	月产 ~50 条	无	高	人力重
每用户一个 Agent	无限，实时生产	有	不可控	随用户数线性增长
中心化 Agent + 个性化分发	**月产 ~1500 条**	**有**	**审核保障**	**固定 + 极低边际**

核心依赖的系统包括：

中心化生产---信号收集与决策系统、内容自动化生产系统

个性化分发---记忆系统、分发系统

二、中心化IP Agent

延续此前规划的逻辑，真正活着的角色应该有**自己想做的事，有自己的生活轨迹**。**用户行为会影响角色的行为**

未来IP行为内容会分两条线，由一个AGENT自主生成：

A. 用户信号驱动

来自用户互动采样 → 意图提取 → 分层设计

> "学生群体在焦虑" → 秃秃假装在看书陪你
>
> 用户吃麦当劳/kfc/必胜客->秃秃也去吃快餐
>
> 有人问我吃鱼→ 秃秃去河边看了鱼，觉得可怕不想吃

核心价值：让秃秃的生活跟用户的生活有呼应

B. 秃秃自主生活

来自秃秃人格定义 × 时间/季节 × soul规划的tutulife

> 秃秃研究人类为什么要用筷子
>
> 樱花季到来秃秃去看樱花

核心价值：让秃秃有自己的生活，不只是回应用户

分发时，两条线混在同一个池子里排序。用户记忆丰富时，信号驱动的行为匹配度更高，大概率看到跟自己生活呼应的，产生预期外的惊喜；记忆还浅或没什么互动时，IP自主的生活浮上来——用户看到IP自己在做有趣的事。

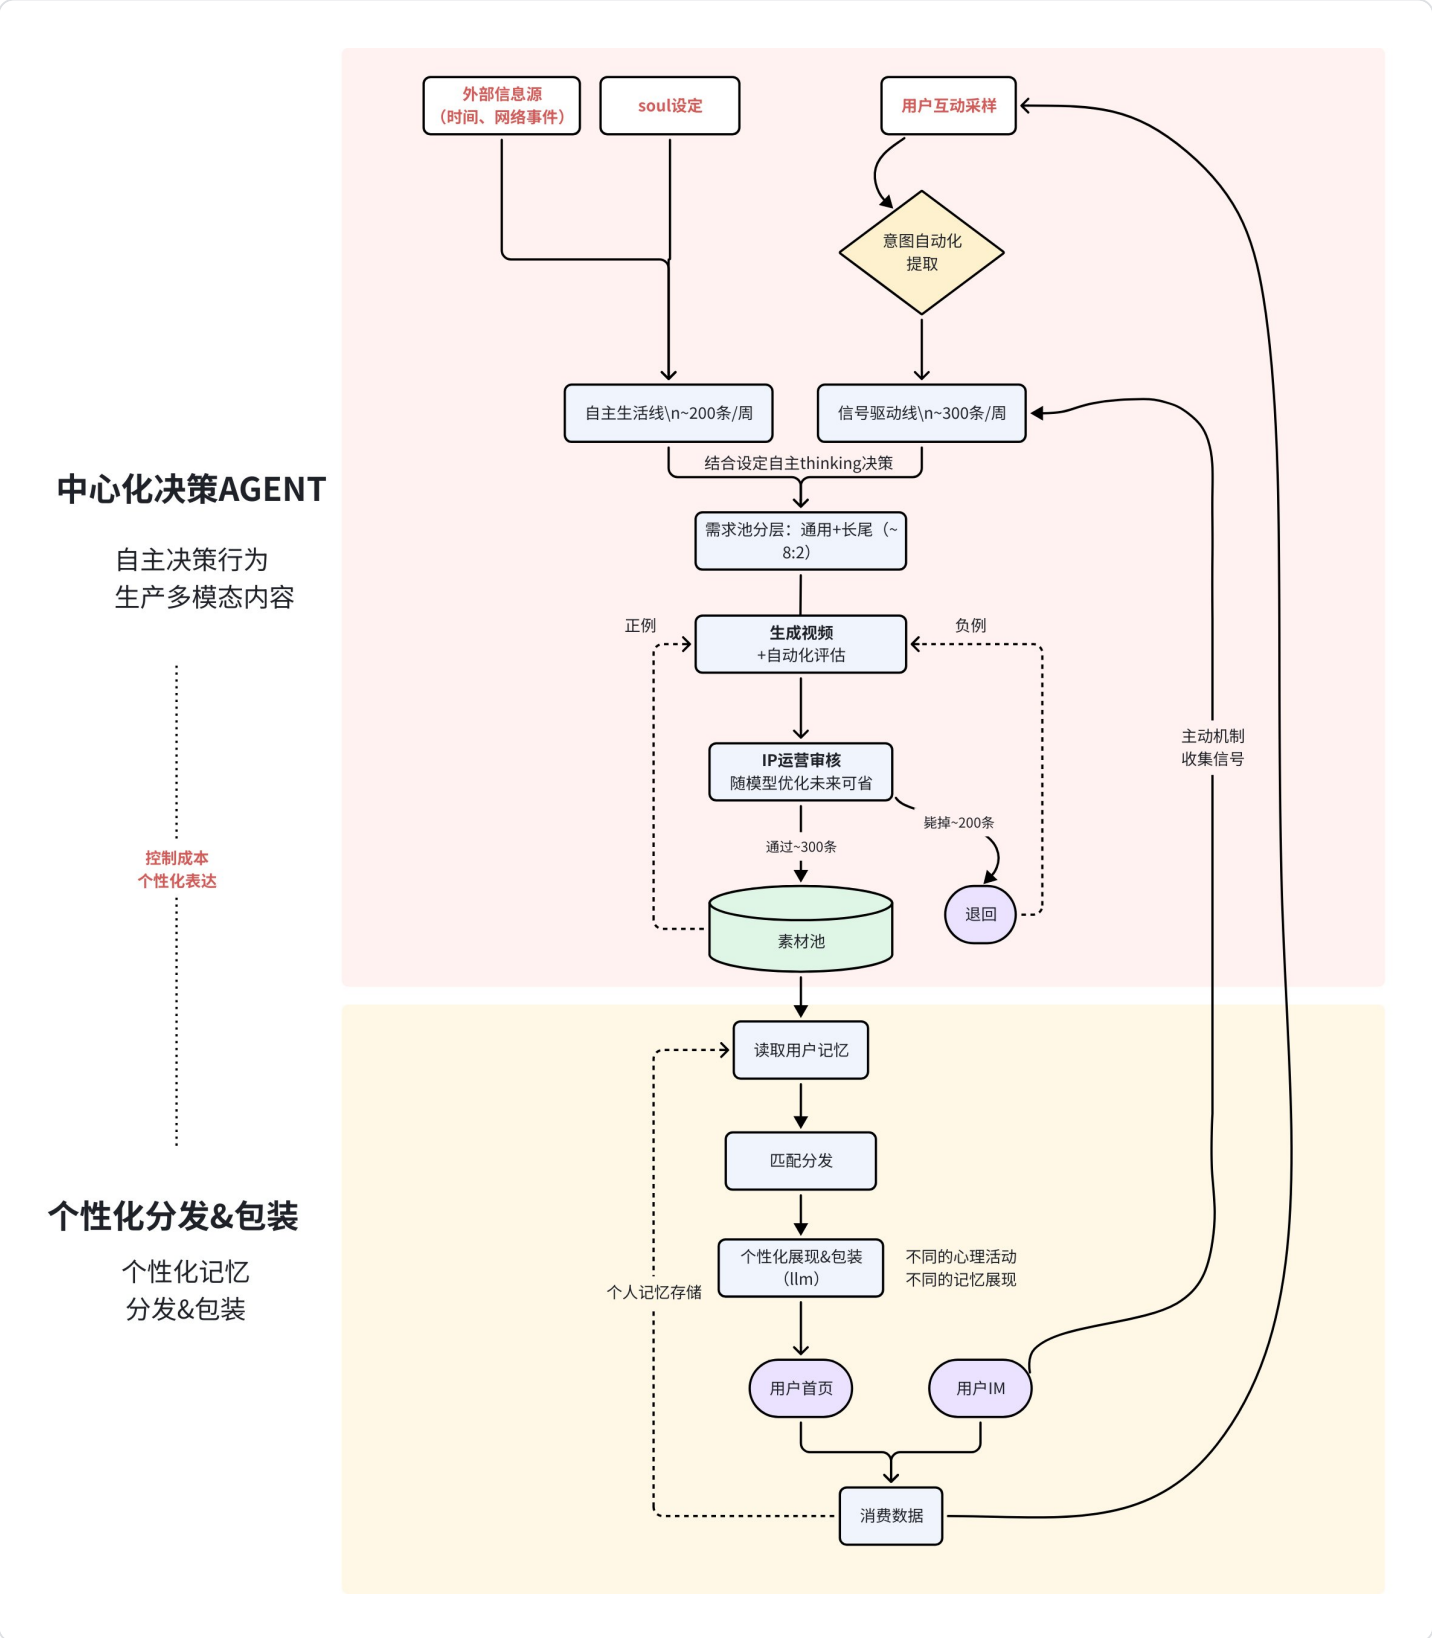

IP AGENT系统完整示意

决策系统

负责收集信号并决策哪些能进入生产池

第一步：提取意图。 Agent 读互动原文，按用户想表达什么做聚类。每个类别覆盖一定比例的用户。

第二步：分层设计。 同一个意图下，Agent 生产三个抽象度的内容：例如用户输入“你要不要吃鱼”；每周 500 条按意图覆盖率分配

> 注：意图不仅是输入，用户经常在中午打开，也是signal

	高抽象（~70%）	中抽象（~20%）	低抽象（~10%）
定义	叙事承载面大，碎碎念可适配该意图下所有用户	对应细分场景，视觉半精准，碎碎念补全	非常具体，素材本身就精准命中，产生最强惊喜感
覆盖	广	中	窄
素材示例	秃秃闻到一种没闻过的香味	秃秃在河边看水里的东西游	秃秃看到鱼跳出水面吓一跳
后期包装 > 碎碎念个性化包装	把"香味"变成鱼味/烤肉味/蛋糕味	补上"鱼"和用户记忆	直接关联"上次有人问我要不要吃这个"

🎁 **核心逻辑：高抽象保覆盖，低抽象造惊喜，按比例分，在分发时包装一层，补回每一层被压缩掉的个性化。**

生产系统

负责基于signal生产**大量**可用内容，是**保证个性化分发的重中之重，需要自动化才能做到**

整体逻辑：将signal翻译成模型可理解的prompt并生成视频->生成的视频先过自动化评估筛掉->前期人工审核把控质量，同时回到模型提供正负例，指导模型能够源源不断产生更高质量的内容，其中

- Agent 负责：批量生成脚本、根据正负例打标和消费数据优化模型和生产逻辑，包括
  - 自动化生产：根据signal生产剧情-转化成分镜prompt-用适合的模型生产-后处理
  - 模型的主动优化：将前期运营打标的正负例&后期用户消费数据，作为参考自动优化模型，补充无法跑出来的

  > 在自研模型ready前先用sd等闭源模型

  - 自动化评估的能力：能够在万级别视频量中挑出badcase&goodcase的能力
- 内容运营负责：维护IP Soul、维护通用的ip自主行为（比如探索人类世界）、审核 Agent 产出打标

目标：

阶段	素材池规模	模型效果		个性化程度
		自动化筛选视频的能力	生产出视频的结果	

第 1 个月	~500 条	能挑出x%的badcase	**分	高抽象兜底为主，碎碎念弥补
第 2 个月	~3,000 条	badcase基本覆盖	**分	中抽象覆盖主要细分
第 3 个月	~8,000 条	能挑出x%的goodcase	**分	低抽象命中常见话题，惊喜感建立
第 6个月	~15,000+ 条	100%自动化	**分	两人同天看到相同内容 < 5%

三、个性化分发与记忆

要解决什么

假设素材池里有上万条秃秃的生活内容。问题是：给谁看哪条？怎么让每个用户觉得"这是我的秃秃"而不是所有人看一样的？

》》两个系统配合：**记忆负责"记录用户&ip的关系"，并转化成特征，分发负责"选适合的内容"。**

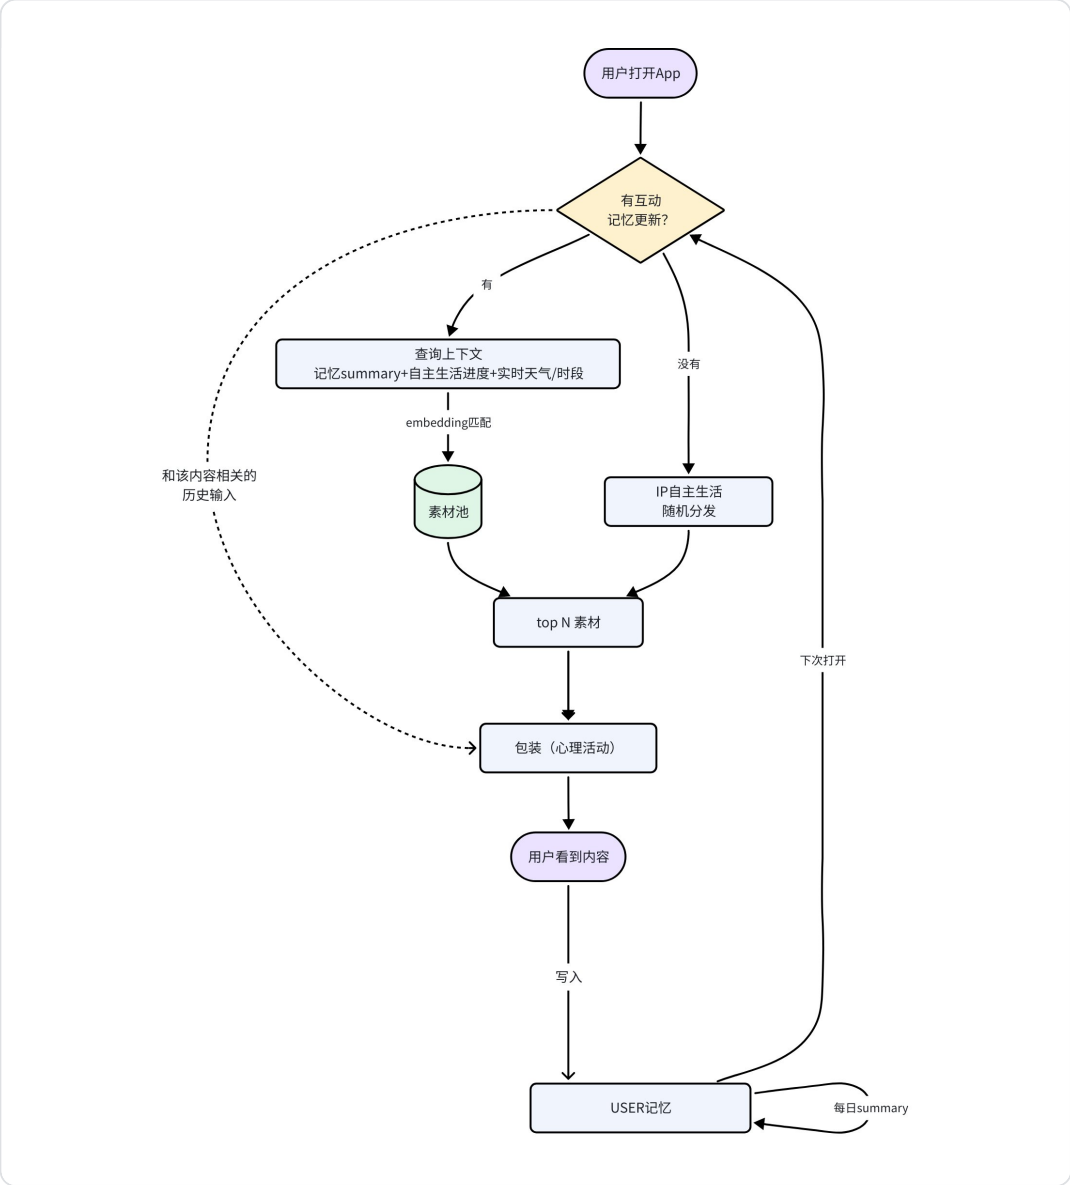

分发系统示意

记忆系统

每个用户有一份记忆档案,从互动中自动积累。

记忆包括：

- **偏好**：这个人经常拍什么（猫、美食、户外…）、喜欢什么调性（治愈、搞笑…）
- **情绪**：最近的状态（活跃时段变了、深夜发照片变多了、互动频率下降了…）
- **关键记忆**：跟秃秃之间有意义的互动节点（"3月22日拍了一只橘猫聊了很久""4月7日问秃秃要不要吃鱼"）
- **基础信息**：昵称、地区、SKU
- **IP在单个用户上的行为进展（？）**：例如探索厨房，出去玩了*次

记忆更新：

- **每次互动时**：用户拍照或发文字，AI 生成秃秃回复的同时，顺便提取记忆更新（偏好变化、新的关键记忆）。不额外调用，搭在已有的回复生成上。

- **每天凌晨（日反思）**：对当天有互动的用户，AI 回顾近期记忆，做一次整体画像更新——发现深层模式（"这个人每次深夜发猫照可能是在缓解压力"）、调整偏好权重、生成当天的菇的记忆日志和推送计划。

记忆是整个系统的核心资产。用户用得越久，记忆越丰富，后面的分发就越精准。

分发系统

用户打开 App（或推送触发、小组件刷新）时，从素材池里选一条最合适的内容展示。

分发触发时机：打开app后实时request

step1：选素材：

- 用户近期有互动的情况：把**用户记忆的summary**（偏好、情绪、近期互动）和**实时上下文**（天气、时段）以及**秃秃自身的状态**（故事弧进度——来自秃秃的人设和自主编排的探索逻辑，比如"这两周在研究筷子"）拼成一段自然语言描述，用 embedding 向量检索素材池，语义匹配出最相关的内容。

> 示例
>
> ```
> 查询文本（实时拼接）：
>  "秃秃正在筷子探索第5天，最近生活方向是食物和探索。
>  这个用户最近三次聊到鱼，喜欢美食和户外。
>  现在是下午，下雨，在上海。"
>
>  ↓ embed
>
> 向量检索素材池（cosine similarity）
>
>  ↓ top K
>
> 最匹配的几条素材
> ```

- 用户无互动更新的情况：按照ip自主生活内容随机分发

step2：包装：选出素材后，基于素材内容 + 用户记忆 + 近期的互动，生成秃秃的碎碎念文案。大部分时候用素材自带的默认文案，记忆中有强关联时追加个性化的内容——"那只猫没有人家那只胖""上次人问我要不要吃这个"。

> 此步骤，是为了当视频与用户关联较弱时，用llm根据用户历史request再包装一次，例如用户提到“吃鱼”，ip总结提炼可能会归到“吃新的美食”，那llm需要在心理活动中展示“上次你提到吃鱼”相关内容；
>
> 技术上要考虑下怎么把历史的“吃鱼”request拼回来->可能在模型决策行为被选中时，就需要记录原始数据（因为视频是会延时生成和推送的，纯靠个人记忆块可能会损失）

step3：数据存储：

- **时段缓存**：同一时段内多次打开看到同一条素材，秃秃不会上一秒钓鱼下一秒回家。时段切换或用户产生新互动时刷新。
- **记忆落盘**：每次被消费过的素材事件内容写入日志，避免记忆串掉

> !! 注：不支持翻看历史记忆，强调实时交互，打开app越多、交互越多，秃秃变化越多，否则就只是分发ip**自主生活的随机内容**

两者怎么配合

记忆积累用户的所有信息，分发每次触发时读记忆做匹配。用户互动写回记忆，记忆变了，下次分发结果就可能变化，同时分发的内容也会进入记忆中，长期滚动达到"越用越懂你"

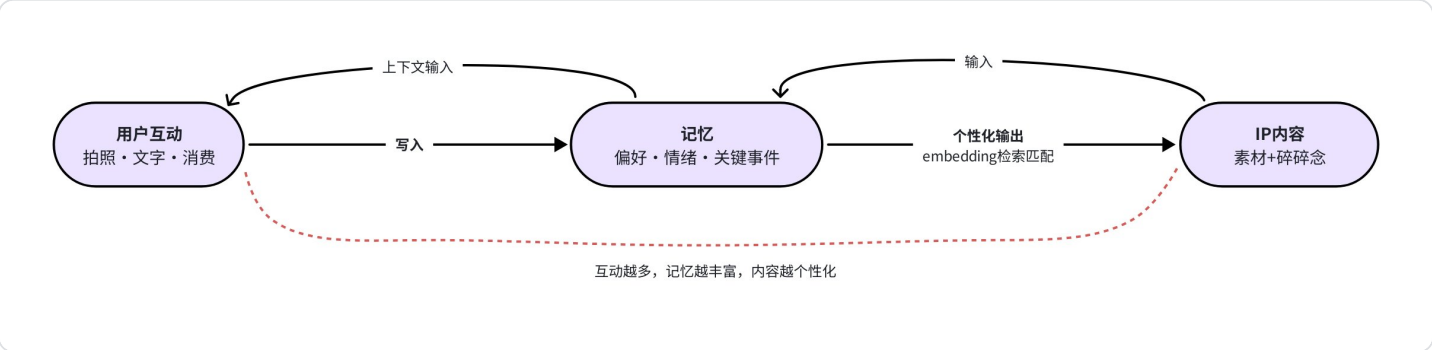

分发举例：同一时刻，三个用户看到完全不同的秃秃

秃秃自己的故事线是"研究筷子 Day5"。三个用户同一天下午打开 App，走实时分发 request，结果完全不同：

	阿梨	小薯条	老王
记忆	爱猫，家有胖橘，近期压力大	爱美食，上周拍过樱花，问过秃秃吃鱼	爱跑步，5天没来
上下文	下午，杭州，阴	下午，上海，下雨	下午，北京，晴
分发逻辑	有互动记忆 → embedding 检索，"猫+压力大+治愈"权重压过筷子弧	有互动记忆 → embedding 检索，"筷子Day5+美食+鱼+雨天"语义匹配	无近期互动 → 按 IP 自主生活分发
素材			

	秃秃在窗边安静待着，旁边一只猫在看（不播筷子内容）	秃秃在屋里用筷子尝试夹东西	秃秃在屋里用筷子尝试夹东西
碎碎念	"旁边那只猫一直盯着我看……没有阿梨家那只胖，但也很安静，想她了"	"夹了半天夹不住……上午看到那条鱼肯定更夹不住"	“筷子真难用”
用户感受	秃秃遇到猫了，还和我家猫对比，好治愈	秃秃还在想我说的鱼！	/

关键区别：小薯条和阿梨有丰富的互动记忆，分发走 embedding 检索，结果高度个性化。老王 5 天没来、无近期互动，分发走 IP 自主生活随机内容——不差，但没有个性化包装。**交互越多，个性化越强。**

四、技术框架与成本

TBD

成本（来自claude，不准）

生产侧（固定投入，与用户数无关）

环节	频率	成本
Agent 批量生成脚本	每周 ~500 条	~$10/周
视频生产	抽卡率10%，每周 ~5000条	seedance~$15k 自研模型~？1/10?
素材 embedding 计算	入池时一次性	~$0.0001/条
内容组审核	每周 ~400 条入审	现有团队人力

分发侧（随用户数增长，但单次极低）

环节	频率	单次成本	10万用户月成本
embedding 检索	每次触发	~$0.0001	~$50
碎碎念（80% 默认 ）	大部分分发	$0	$0

碎碎念（20% AI 生成）	高价值场景	~$0.001	~$1,800
即时回复（含实时记忆提取）	每次互动	~$0.003	~$3,000
日反思（按活跃度分层）	每天，仅活跃用户	~$0.0005-0.002	~$720

月总计（10 万用户）：生产~$60,000(sd)，分发&llm~$5,000，约rmb40w，使用自研模型将大幅降低生产成本到1/10，约rmb 6w

五、Milestones&版本规划

目标是2.0能用上agent个性化系统

关键版本	**TUTU 1.0 软件**	**独立部署AGENT预览版**	**中心化IP AGENT**	**TUTU 2.0 软件**
目标	商业化产品配套售卖	融资&产品展示	验证作为正式产品的系统可行性	Agent逻辑应用正式产品 软硬件互动
时间	5.10 - MVP	4.30前第一版主流程 主流程包括chatbot+ai生成的内容主页，不包括ugc vlog，做完再看要不要增加更多for展示的feature 5.10 目标千级别的可分发视频，由agent预生产，实现即时体验	6.15	8月
核心feature	预制好的IP视频内容，用户可以输入图片互动，能生成个性化记忆 Sowii · 1.0 PRD • ChatBot：支持上传图片、llm自动生成心理活动 • IP的内容主页：暂时用人工生产的PGC内容&心理活动 • 菇的记忆	独立agent方式运行，用户可以文字&图片互动，IP能随用户输入改变行为，多模态展示 • 完整的Chatbot：图片、文字对话 • IP的内容主页：根据用户交互&IP soul，自动生产的IP内容 • llm驱动的完整心理活动	中心化生产、个性化分发，用户交互越多，看到的ip与用户关联越多 具体如上文所述	中心化agent能work上的基础上增加 • 硬软件互动 • 多sku的不同内容自动化生产 • 更丰富灵活有趣的UGC能力

		• 菇的记忆		
技术依赖	• ChatBot基础框架 • memory：编排的事件、历史上传的照片、获得的道具等 • 分发基础框架	• ChatBot完整框架 • memory：事件、关键记忆、历史交互；实时信息（天气、时间等） • 根据上下文，自动生成心理活动和视频内容的工作流 > 质量上需要调，小爱的还不大行	• signal收集与行为决策（llm） • 自动化内容生产系统达到80分 • 用户独立的memory架构 • 个性化分发系统	• 内容自动化生产达到80分，且支持多sku，成本可控 • 整个工程稳定、成本可控 • 硬软件互动独立能力